技術コミュニティの成長性を加味した特許価値評価手法の開発

Development of the patent values evaluation method considering growth of technical community

山本　雄太 *1　野中　尋史 *1　邊土名　朝飛 *1　中井　堅誠 *1　作本　猛 *1
Yuta Yamamoto　Hirofumi Nonaka　Asahi Hentona　Kensei Nakai　Takeshi Sakumoto
片岡　翔太郎 *1　平岡　透 *2
Shotaro Kataoka　Toru Hiraoka

*1長岡技術科学大学　*2長崎県立大学
Nagaoka University of Technology　University of Nagasaki

We propose a patent value evaluation method considering the growth potential of the technical community. The patent value is calculated by combining the patent value calculated based on the PageRank algorithm and the growth prediction of the technical community to which the patent belongs. The feature of this method is that it automatically detects the technical community from the link relation between patents in the technical field based on IPC. In this paper, we performed automatic detection of the technology community using x-means and Node2Vec, and predicted the growth potential of the technology community using ARIMA. As a result, for the largest technical community in the A to H sections of the IPC, we were able to predict the accuracy of 80 to 90% in the majority of the sections.

1.　研究背景

特許情報は，業界の動向や企業・国の競争力の評価に利用できることが知られており [Chakrabarti 94]，特許情報処理に関する研究が行われてきた [酒井 09]．特許情報から特許の重要性を定量的に評価する特許価値評価手法は，知財・研究開発・投資戦略策定等の観点からニーズが高く，従来より様々な研究が実施されてきた．特許価値評価手法の中では，特許の引用数が企業価値に大きく影響することが明らかになっている [Hall 05]．

しかし，全ての特許の重要性が等価であるとは考えにくい．例えば，価値の高い特許を引用した特許は同様に価値が高いと考えられ，さらにその特許を引用した特許も同様に価値が高いと考えられる．よって，引用（リンク）ネットワーク全体から特許価値を評価する必要がある．そこで Lukach らは，リンクネットワークに基づいた特許価値評価手法として，PageRank[Brin 98] を利用することを提案した [Lukach 07]．この研究では，PageRank アルゴリズムに基づいて計算した特許価値の傾向は引用数に基づいて計算した特許価値の傾向と異なっていることを示した．さらに野中らは，PageRank と同様のネットワーク評価アルゴリズム HITS[Kleinberg 99] に基づいた特許価値と関連会社との株価の間にある相関性を計算した [Nonaka 14]．この研究では，BtoB 企業の特許価値と株価との間に高い相関関係があることを発見し，価値評価にネットワーク評価アルゴリズムが有効であることを明らかにした．また Bruck らは，特許文書に PageRank に基づいた特許価値を用いることで，将来の技術開発に予測できることを示した [Bruck 16]．これらの研究を総合すると，引用情報とは異なる観点から，有効な特許価値を評価できることが示唆される．

しかし，PageRank アルゴリズムを中心としたネットワーク評価アルゴリズムは特許の引用数という静的な情報に基づいているため，その特許の属する技術分野の成長可能性を重要度に反映することができない問題を抱えていた．例えば，既に成熟しており成長可能性の低い技術分野の特許は，今後価値が低下していくと考えられる．しかし，成熟した技術分野の特許はその分大量のリンク関係が存在しているため，静的な情報に基づいた価値評価手法では価値を高く評価してしまう．この問題を解決するためには，各分野の成長可能性を予測したうえで，それを加味した価値評価手法を確立する必要がある．しかし，従来の特許研究で技術分野の分類コードとして使用されてきた IPC（International Patent　Classification，国際特許分類）に基づいた分類では，新しい技術分野や粒度が低すぎるため詳細な技術分野を検出するこができない．そこで本研究では，引用ネットワークに基づく小規模な技術分野である技術コミュニティを自動的に検出することを行い，さらに，技術コミュニティごとに成長性を予測したうえで特許価値を評価する手法の開発を行った．

連絡先: 山本雄太，長岡技術科学大学　情報・経営システム工学課程，〒 940-2137 新潟県長岡市上富岡町１６０３－１
知識マイニング研究室，s193378@stn.nagaokaut.ac.jp

2.　提案手法

2.1　提案手法全体の概要

本研究で提案する手法の概要を図 1 に示す．提案手法では，PageRank に基づいた特許価値と技術コミュニティの成長性予測の 2 要素を組み合わせることで，特許価値を算出する．

このうち本論文では，技術コミュニティの成長性予測について記述する．

2.2　成長性予測手法の概要

本研究の成長性予測手法の概要を図 2 に示す．この手法では，次のような手順で技術コミュニティの成長性を予測する．(1) 特許データベースから引用ネットワークを作成 (§2.3)．(2) 作成した引用ネットワークから技術コミュニティを検出 (§2.4)．(3) 各コミュニティの成長性を予測 (§2.5)．

2.3　引用ネットワークの作成

次の手順で，特許データベースから引用ネットワークを作成する．(1) 特許データベースから特許の引用情報を抽出．(2) 抽出した引用情報から引用ネットワークを作成．この (1), (2) の手順を IPC に基づいて分類した技術分野ごとに行う．

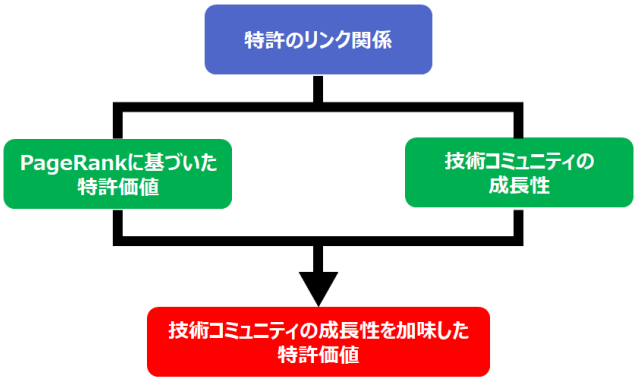

図 1: 提案する価値評価手法の概要

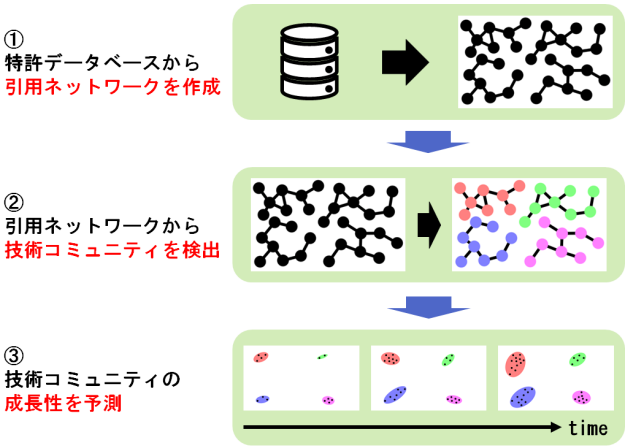

図 2: 提案手法の概要

2.4 技術コミュニティの検出

引用ネットワークから技術コミュニティを検出する．技術コミュニティの検出はクラスタリングによって行う．クラスタリングには x-means を使用する [Pelleg 00]．クラスタリングに x-means を使用することで，各引用ネットワークごとに最適なクラスタ個数でクラスタリングを行えるようになる．クラスタリングを行えるようにするために引用ネットワークを Node2Vec に入力し，各ノードを低次元のベクトルに変換する [Grover 16]．

2.5 各技術コミュニティの成長性予測

次のような手順で技術コミュニティを時系列解析し，各コミュニティの成長性を予測する．

2.5.1 時系列データの作成

次のような手順で技術コミュニティから時系列データを作成する．(1) あるコミュニティ内のある 1 つの特許について，その特許を引用した特許の出願日を取得．(2) 次に，取得した出願日から月ごとの引用数として時系列データを作成．

2.5.2 時系列データの将来性

作成した時系列データを時系列解析モデルに入力し．将来の時系列を予測する．時系列解析モデルには ARIMA を使用する [Abu Bakar 17]．ARIMA を採用した理由としては，本研究と同様の先行研究にて最も将来予測の精度が高いモデルだったことが挙げられる [Hentona 18]．

3. 実験

3.1 実験条件

本研究では，次のよう条件で実験を行った．

使用した特許データベースは，日本の知的財産研究所（IIP）のものを使用した．このデータベースには，1960 年から 2017 年までの約 6,000,000 件の特許が格納されている．

対象とした特許は，このデータベースに格納されている 5 種類のテーブルのうち，出願日などの情報を含んでいる出願テーブルに記録されているものとした．

引用ネットワーク作成の際に使用した IPC は，このテーブルに格納されている「特許の公開・公表の筆頭 IPC」とした．これは，IPC におけるセクション，クラス，サブクラスを表す 4 桁の記号である．

時系列データのうち，ARIMA に入力した期間（学習期間）は 1980 年 1 月から 2000 年 12 月までとした．予測期間は 2001 年 1 月から 12 月までを予測した．

予測対象とした技術コミュニティは，IPC における各セクション (A〜H) ごとに，最もデータ件数の多かったクラスタとした．

予測精度の評価指標には対称平均絶対パーセント誤差 (SMAPE) を使用した．SMAPE の式を (1) 式に示す．

$$SMAPE = \frac{100\%}{N} \sum \frac{|F_t - A_t|}{(|A_t| + |F_t|)/2} \tag{1}$$

N がデータ件数，F_t が予測値，A_t が実測値を意味する．今回の場合，2001 年 1 月から 12 月までを予測したので $N = 12$，F_t は ARIMA による同期間の予測値，A_t が同期間の時系列データとなる．なお，Hentona らの研究では平均絶対パーセント誤差 (MAPE) を使用して予測精度を評価していたが，MAPE では予測期間の実測値に引用件数が 0 件の月があった場合に計算不能となってしまう問題があるため，本研究では SMAPE を採用した [Hentona 18]．

3.2 実験結果

今回の成長性予測によって得られた，各セクションでの SMAPE の値を図 3 に示す．

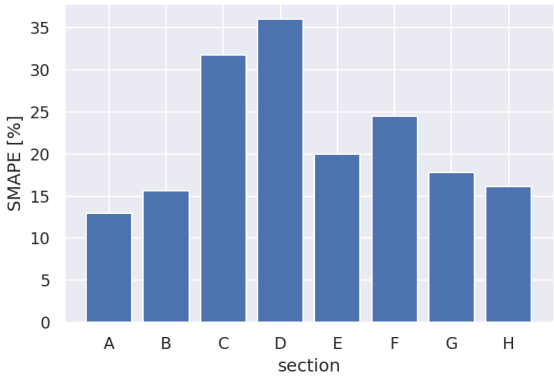

図 3: 各セクションでの SMAPE の値

図 3 より，A, B, E, G, H の 5 つのセクションで 10 %〜20 %の SMAPE スコアが得られた．したがって，セクション全体のうち過半数のセクションで 80 %〜90 %の精度の予測を行うことができた．また，他のセクションと比べて C, D のセクションは突出して SMAPE スコアが高くなった．

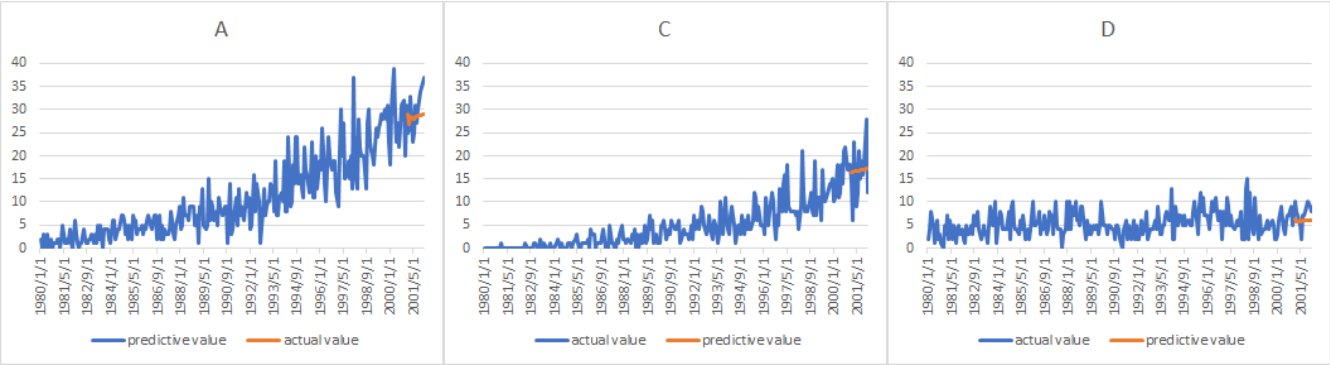

図 4: セクション A, C, D での実測値と予測値の比較（全期間）（横軸：学習期間と予測期間，縦軸：リンク件数）

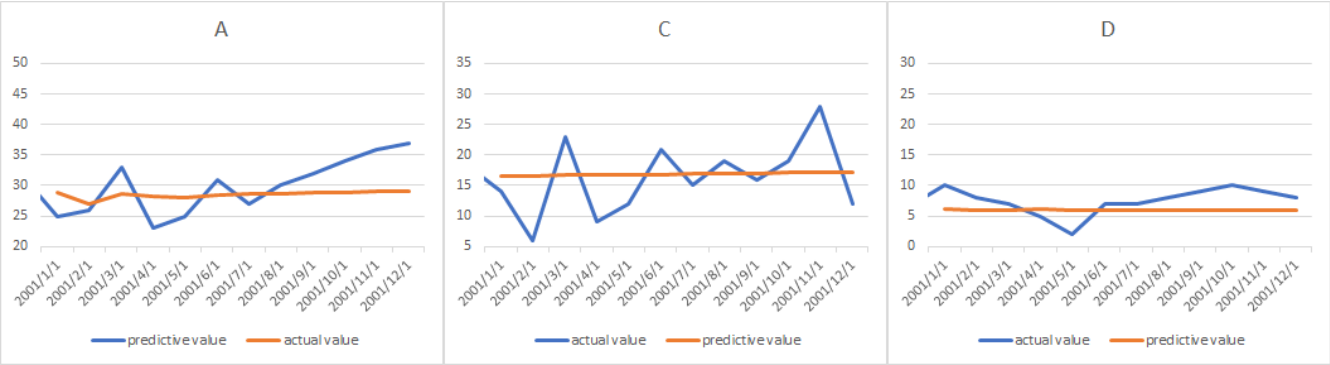

図 5: セクション A, C, D での実測値と予測値の比較（予測期間）（横軸：学習期間と予測期間，縦軸：リンク件数）

4. 考察

セクション C, D の SMAPE スコアが高くなった原因として，この 2 つのセクションの予測期間の実測値の分散が大きかったことが考えられる．

SMAPE スコアが最も低かったセクション A と，突出して高かったセクション C, D について，実測値と予測値を比較したものを図 4，図 5 に示す．セクション C の SMAPE スコアが高かった原因としては，学習期間中には見られなかった値のブレが予測期間中に現れていたことが挙げられる．セクション D の SMAPE スコアが高かった原因としては，そもそも学習期間中の値のブレが大きかったためにうまく学習できなかったことが挙げられる．

5. 今後の展望

本論文では，提案手法のうち技術コミュニティの成長性予測のみについて述べた．学会当日では，本論文で述べた成長性予測と 2.1 説で触れた PageRank による特許価値とを組み合わせた，提案手法全体について発表する．また，時系列解析モデルも ARIMA 以外の手法との比較検討を行う予定である．

謝辞

本研究の実施に際して研究助成していただきました電気通信普及財団に心より感謝いたします．

参考文献

[Abu Bakar 17] Abu Bakar, N. and Rosbi, S.: Autoregressive Integrated Moving Average (ARIMA) Model for Forecasting Cryptocurrency Exchange Rate in High Volatility Environment: A New Insight of Bitcoin Transaction, *International Journal of Advanced Engineering Research and Scinece*, Vol. 4, (2017)

[Brin 98] Brin, S. and Page, L.: The Anatomy of a Large-Scale Hypertextual Web Search Engine, in *Seventh International World-Wide Web Conference (WWW 1998)* (1998)

[Bruck 16] Bruck, P., Réthy, I., Szente, J., Tobochnik, J., and Érdi, P.: Recognition of Emerging Technology Trends. Class-selective study of citations in the U.S. Patent Citation Network, *CoRR*, Vol. abs/1602.07928, (2016)

[Chakrabarti 94] Chakrabarti, C. K. and Dror, I.: Technology transfers and knowledge interactions among defence firms in the USA: an analysis of patent citations, *International Journal of Technology Management*, Vol. 9, pp. 757 – 770 (1994)

[Grover 16] Grover, A. and Leskovec, J.: node2vec: Scalable Feature Learning for Networks, *CoRR*, Vol. abs/1607.00653, (2016)

[Hall 05] Hall, B. H., Jaffe, A., and Trajtenberg, M.: Market Value and Patent Citations, *The RAND Journal of Economics*, Vol. 36, No. 1, pp. 16–38 (2005)

[Hentona 18] Hentona, A., Nonaka, H., Nakai, K., Sakumoto, T., Kataoka, S., Alemán Carreón, E., España, H., Hiraoka, T., and Hirota, M.: Community Detection and Growth Potential Prediction from Patent Citation Networks, pp. 204–211 (2018)

[Kleinberg 99] Kleinberg, J. M.: Authoritative Sources in a Hyperlinked Environmen, *J. ACM*, Vol. 46, pp. 604 – 632 (1999)

[Lukach 07] Lukach, R. and Lukach, M.: Ranking uspto patent documents by importance using random surfer method (pagerank), *SSRN Electronic Journal*, pp. – (2007)

[Nonaka 14] Nonaka, H., Kubo, D., Kimura, T. H., Ota, T., Masuyama, S., et al.: Correlation analysis between financial data and patent score based on HITS algorithm, in *2014 IEEE International Technology Management Conference*, pp. 1–4IEEE (2014)

[Pelleg 00] Pelleg, D.: X-means : Extending K-means with Efficient Estimation of the Number of Clusters, *Proc. of the 17th International Conference on Machine Learning, 2000*, pp. 727–734 (2000)

[酒井 09] 酒井浩之, 野中尋史, 増山繁：特許明細書からの技術課題情報の抽出, 人工知能学会論文誌, Vol. 24, No. 6, pp. 531–540 (2009)